

생성형 AI 대규모 언어모델을 활용한 LLAMA-SDF 개발

손고은 서울디지털재단 선임

이진규 동국대학교 인공지능대학원 박사과정

정성엽 한국산지보전협회 연구원



Seoul Digital Foundation
서울디지털재단



Contents

AI 서비스 연구개발

생성형 AI 대규모 언어모델을 활용한 LLAMA-SDF 개발

제1장 연구 개요 1

- 1. 연구 배경 2
- 2. 연구 목표 6

제2장 연구 수행 9

- 1. 해커톤 연계 모델 구조 분석 및 대표 과업 선정 10
- 2. 모델 개발을 위한 대규모 언어모델의 선정 11
- 3. 모델 개발 및 성능 고도화 작업 24

제3장 결론 43

참고문헌 46

Contents

표목차

[표 1-1] 생성형 AI 기술의 대표적인 보안 위협[1]	4
[표 1-2] 대규모 언어모델 활용 방안	5
[표 2-1] 세부 과업(Sub-Task) 역할	10
[표 2-2] 주요 Benchmarks에 대한 성능 측정 결과[10]	15
[표 2-3] Polyglot-ko 파라미터별 성능 측정 결과[11]	16
[표 2-4] Llama2-ko-7b-chat 모델 소개	17
[표 2-5] Llama2-ko-7b-chat License 관련 주요 내용[13]	17
[표 2-6] KULLM License 관련 주요 내용[15]	18
[표 2-7] Fine-tuning 파라미터 값	19
[표 2-8] Llama2-ko-chat와 KULLM 의 세부적인 답변 제공 여부 비교	21
[표 2-9] Llama2-ko-chat와 KULLM 간의 답변 풍부도 비교	22
[표 2-10] Llama2-ko-chat와 KULLM 간의 정확도 비교(랜덤 샘플 추출)	23
[표 2-11] Llama2-ko-chat와 KULLM 모델 최종 비교	24
[표 2-12] Llama2-ko-chat 파라미터 변경 사항	28
[표 2-13] Instruction 항목에 CoT 기법 적용 결과 예시	31
[표 2-14] Input 항목에 CoT기법 적용 결과 예시	32
[표 2-15] Instruction과 input 항목에 CoT 기법 적용 결과 예시	34
[표 2-16] Reward model scoring 결과	41

그림목차

[그림 1-1] 생성형 AI 시장 전망 (좌: 리서치 앤 마켓[2], 우: 테크나비오[3])	3
[그림 1-2] 2023 서울시 생성 AI 해커톤 우승작 - '어디답뱃' (디지털 교육 맞춤형 챗봇 서비스)	6
[그림 1-3] 모델 성능 고도화 방안[5]	7
[그림 2-1] 모델에 따른 서빙 비용 비교[6, 재가공]	12
[그림 2-2] 생성형 AI 기반 대규모 언어모델 공개 현황[7]	13
[그림 2-3] Llama2 70B GPU 할당량(T4 8개 기준 47.35GB)[8][9]	14
[그림 2-4] Llama2 7B GPU 할당량	14
[그림 2-5] Llama2 모델 각 나라 언어별 사전학습 비율 비교[12]	16
[그림 2-6] KULLM 성능 평가결과[14]	18
[그림 2-7] LoRA 방식을 사용한 정확도 측정 결과[16]	19
[그림 2-8] Llama2-ko-chat 와 KULLM 간의 세부적인 내	22
[그림 2-9] SFT(Supervised Fine-Tuning) 데이터셋 예시	26
[그림 2-10] Llama2-ko-7b-chat의 생성문과 테스트셋 비교	27
[그림 2-11] max_new_tokens, repetition_penalty 파라미터 조절 결과	28
[그림 2-12] 예시 기반 prompt learning 방식[22]	29
[그림 2-13] 사고 기반 prompt learning 방식[22]	30
[그림 2-14] Instruction에 CoT 방법 적용	31
[그림 2-15] Input에 CoT 방법 적용	31
[그림 2-16] LoRA 가중치 고정 방식[23]	35
[그림 2-17] LoRA 적용 전/후 GPU 메모리 할당량[24]	36
[그림 2-18] Llama 2-chat SFT와 RLHF Fine-tuning 방법[12, 재가공]	37
[그림 2-19] SFT와 RLHF 기반 답변 생성 프로세스[25]	38
[그림 2-20] BERT 기반의 reward model	39
[그림 2-21] Reward model scoring 예시	39
[그림 2-22] Reward model을 통한 scoring 예시(history 기반 dataset)	40
[그림 2-23] Reward model 학습 과정	41

SEOUL

DIGITAL

FOUNDATION

AI 서비스 연구개발

생성형 AI 대규모 언어모델을 활용한 LLAMA-SDF 개발

제1장

연구개요

제1장 | 연구개요

1 연구 배경

■ 생성형 AI(Generative AI)¹⁾의 발전에 따른 인공지능 패러다임의 변화

- 기존의 인공지능은 데이터 분석 및 예측 분야의 연구 영역에서 활용되고 기본적인 업무를 보완하는 형태의 보조도구 역할로 사용됨
- 기존 인공지능은 학습된 데이터의 특징을 기반으로 예측과 분류하는 작업에 머물렀다면, 생성형 AI는 스스로 탐색하고 추론하는 창조의 영역까지 확대되었음
- 생성형 AI의 발전은 인공지능 패러다임을 순식간에 변화시켰고, 사회·경제적 혁신과 더불어 사람들의 일상생활까지 변화시키고 있음

■ 챗GPT의 등장으로 인한 대규모 언어모델(Large Language Model, LLM)²⁾ 개발 열풍

- 오픈AI사의 챗GPT의 등장은 생성형 AI 기반의 대규모 언어모델(이하 LLM)에 대한 전 세계 대중뿐만 아니라 빅테크 기업의 관심을 집중시킴과 동시에 자체 대규모 언어모델 개발에 열풍을 일으킴
- LLM은 방대한 양의 데이터와 수천억 개 이상의 파라미터를 학습하여 예측·추론하는 모델로, 이를 개발하기 위해 국내·외 빅테크 기업들은 자체 기술 개발 및 시장 선점을 위해 많은 자본을 투자하고 있음
 - 글로벌 생성 AI 시장 보고서(2023-2028) - Research And Markets 생성형 AI 시장은 2023년 113억 달러에서 연평균 성장률 35.6%로 2028년에는 518억 달러로 성장할 것이라 전망

1) 생성형 AI : 텍스트, 오디오, 이미지 등 기존의 콘텐츠를 바탕으로 비지도 학습 기반 기존 데이터와 비교 학습을 통하여 새로운 창작물을 생성해내는 기술

2) 대규모 언어모델(Large Language Model, LLM) : 대화 또는 자연어 입력 시 인간과 유사한 응답을 생성하기 위하여 방대한 양의 텍스트 데이터를 학습하고 훈련한 언어모델을 의미

- 생성AI 시장 전망과 분석 2023~2027년 보고서 - 테크나비오(Technavio)
- : 2022~2027년에 연평균 32.65% 성장, 2027년 생성AI 시장 규모는 2022년보다 346억 9,537만 달러 증가할 것으로 전망

[그림 1-1] 생성형 AI 시장 전망 (좌: 리서치 앤 마켓[2], 우: 테크나비오[3])



- 현재까지 개발된 생성형 AI 기반 LLM은 대표적으로 오픈AI의 GPT 시리즈와 메타의 Llama, 구글의 PaLM, 네이버의 HyperCLOVA를 들 수 있음

■ 정부 및 지자체의 업무 개선을 위한 LLM 활용을 제안

- 정부 및 지자체에서는 챗GPT와 같은 LLM을 활용한 업무 방식의 혁신 및 개선을 적극적으로 제안하고 추진 방안에 대한 계획을 수립하고 있음
- 국내 정부는 ‘디지털플랫폼정부위원회’를 중심으로 국내 정부에 특화된 초거대 AI 개발을 진행 중에 있으나 현재 보안 문제로 생성형 AI 활용에 대한 계획 수립 단계 수준에 머물러 있음
- 정부 및 지자체에 생성 AI 기반의 LLM 도입을 위해서는 모델 학습 및 연산을 위한 메모리 공간과 컴퓨팅 파워가 필수적이며, API 이용한 서비스 이용 시 모델 크기, 호출 수, 사용 시간 등의 비용적 측면과 동시에 보안성 문제도 제기되고 있음
 - 비용성 : 대규모 언어모델 사용 시 발생하는 비용(토큰 당 사용료, GPU 메모리, 서버 운영비 등)
 - ※ GPT4-turbo : 입력 토큰 1,000개 당(약 750단어) \$0.01, 출력 토큰 1,000개당 \$0.03 부과
 - 보안성 : API를 이용한 데이터 통신 및 미세조정 등에 대한 작업 시 개인정보, 민감 정보, 보안자료 등의 외부 유출 가능성 존재

[표 1-1] 생성형 AI 기술의 대표적인 보안 위협[1]

대표 보안 위협	주요원인	가능한 보안 위협
잘못된 정보	- 편향 - 최신 데이터 학습 부족 - 환각 현상	- 사회적 혼란 조장 - 고위험 의사 결정 - 잘못된 의사 결정 유도
AI 모델 악용	적대적 시스템 메시지	- 피싱 이메일 및 인물도용 - 사이버 보안 위협 코드 작성 - 대화형 서비스를 악용한 사이버 범죄 커뮤니티 활성화 - 사회 공학적 영향 - 가짜 뉴스 생성
유사 AI 모델 서비스 빙자	유사 악성 서비스 접근 유도	- 스캠 URL 및 확장 프로그램 - 가짜 애플리케이션
데이터 유출	- 데이터 합성 과정의 문제 - 과도한 훈련 데이터 암기 문제 - 대화 과정에서 개인정보 및 민감 정보 작성	- 훈련 데이터 유출 - 데이터 불법 처리 우려 - 기밀 유출 - 대화 기록 유출 - 데이터베이스 해킹 및 회원 추론 공격
정보 작성	- AI 모델의 적용 범위 확장 - 안정성 확인 미흡 - 해커 공격 범위 확장 - 취약점이 있는 서비스와 연결	- 새로운 도메인에서의 모델 오작동 '에이전트'화 된 AI 모델의 악용 - 멀티모달 악용
플러그인 취약점	- 확장 프로그램 내부의 악성 서비스 설치 - 서비스 제공 업체의 보안 조치 미흡	- 개인정보 수집 - 시스템 공격 - 호스팅 서버 및 스토리지 시스템 위협
확장 프로그램 취약점	- 미흡한 API 키 관리 - 데이터와 명령 사이의 불분명한 경계	- API 키 탈취 - 악의적인 프롬프트 주입

- 다양한 문제점에도 불구하고 몇몇 지자체에서는 민원 상담 업무의 어시스트 개념으로 생성형 AI 기반 서비스를 도입하여 적용하고 있으며, 특정 기관에서는 자체 LLM 구축을 통한 업무 처리 개선에 박차를 가하고 있음
 - 예시 : 검찰청(사건처리 업무 지원 생성형 AI 활용 시나리오 연구), 통계청(통계 추천 및 분석지원, 통계 전문 질의 답변 서비스) 등

■ 생성형 AI 기반의 LLM 도입을 위한 사전 검토

- 생성형 AI 기반 LLM이 전 세계의 이목을 끄는 이유는 다음과 같음[4]
 - 다양한 분야의 지식 학습 : 여러 분야의 지식을 다각도로 폭넓게 학습함
 - 언어의 이해 능력 : 여러 언어에 대하여 문장의 문맥을 이해하고 창의적인 결과물을 제시
 - Few-shot : 적은 수의 학습으로도 높은 성능을 보임
 - 다양한 API 서비스 : 다양한 기업에서 제공하고 있는 유료 API 서비스
- LLM을 활용하기 위한 방안을 살펴보면 다음과 같음

[표 1-2] 대규모 언어모델 활용 방안


활용 방안	특징	장점	단점
API 서비스	챗GPT, HyperCLOVA와 같은 서비스 이용	• 고성능 • 사용량에 따른 비용 청구 • 빠른 사용성 • 적은 개발 인력	• 서비스 의존성 • 고비용 • 보안 위협 • 유저 당 요청 수 한계
작은 언어모델	BERT, GPT-2 등의 10억 개 이하의 작은 언어 모델 활용	• 결과물의 자율성 • 보안성 확보 • 저비용(CPU 사용, 학습비용)	• 성능 제한 • 미세조정 학습 데이터 구축 필수 • 많은 개발인력 • 성능 수준 미지수
오픈소스 대규모 언어모델	Llama, Polyglot 등의 적은 파라미터를 가진 오픈소스 기반 대규모 언어모델 활용	• 우수한 성능 • 보안성 확보 • 추가 학습 및 개선이 가능	• 많은 개발 인력 • GPU 서빙 비용

2 연구 목표

■ 생성형 AI 기반 오픈소스 LLM을 활용한 SDF 자체 모델 개발

- 대규모 언어모델의 경우 LLM의 사전학습 모델 개발과 기존의 모델을 미세조정하는 방법, API 사용한 응용·개발하는 방안으로 나누어짐
- 본 연구에서는 정부 및 지자체에서 생성형 AI 기반 언어모델의 도입 시 발생하는 대표적인 문제점(보안성, 경제성, 인력)에 착안하여 사전 학습된 LLM을 활용한 서울디지털재단의 자체 모델을 개발하고자 함
- 모델의 개발은 내부망 서빙이 가능한 오픈소스 기반의 생성형 언어모델을 활용하고, 기 개발된 오픈소스 기반의 응용 모델을 벤치마킹하여 추진하고자 함
- 개발된 모델은 2023 서울시 생성 AI 해커톤³⁾ 우승작과 연계하여 어르신을 대상으로 한 디지털 의문점에 대한 질의응답 환경을 제공할 수 있는 서비스로 연계하고자 함

[그림 1-2] 2023 서울시 생성 AI 해커톤 우승작 - ‘어디답뱃’(디지털 교육 맞춤형 챗봇 서비스)



※ ‘디지털 교육 맞춤형 챗봇 서비스’ 구조


생성형 인공지능을 중심으로 사용자 질문을 적절한 세부 과업으로 나눈 후, 배분된 과업에 맵핑된 모델을 활용해 추론하여, 추론 결과를 기반으로 적절한 답변을 생성하여 제공

3) 2023 서울시 생성 AI 해커톤 : 생성형 AI 활용, 혁신적 공공서비스 발굴·개발을 위한 해커톤(서울디지털재단-120다산콜재단 협업 주최)

■ 모델 고도화 방안을 통한 성능 향상 도모

- 생성형 AI의 고질적인 문제인 환각현상(Hallucination)을 줄이기 위해 모델의 학습 시 사용하는 학습 데이터셋을 모델 개발 후 적용될 서비스에 부합하도록 재단에서 보유하고 있는 어르신 포용 콘텐츠 106종을 활용하고자 함
- 모델의 성능을 고도화 할 수 있는 다양한 방법 중 적용 가능한 방안을 선정하여 최적화하는 작업을 수행하고자 함

[그림 1-3] 모델 성능 고도화 방안[5]



SEOUL

DIGITAL

FOUNDATION

AI 서비스 연구개발

생성형 AI 대규모 언어모델을 활용한 LLAMA-SDF 개발

제2장

연구 수행

제2장 | 연구 수행

1 해커톤 연계 모델 구조 분석 및 대표 과업 선정

1) 2023 생성 AI 해커톤 우승작인 ‘어디답벳’ 모델 구조 및 프로세스

■ 해커톤 우승작인 ‘어디답벳’ 모델의 구조와 프로세스 파악

- 어디답벳은 단일 과업(Task)이 아닌 여러 개의 세부 과업(Sub-Task) 모델을 사용한 멀티모달 환경에 적응할 수 있는 모델임
- 어디답벳 모델은 GPT 3.5 Turbo를 중심모델로 하여 사용자의 요청사항과 세부 과업에 따라 순차적으로 수행하도록 설계되어 있음

[표 2-1] 세부 과업(Sub-Task) 역할

세부 과업	수행 방안
이미지 분류	Resnet을 사용하여 사용자 입력 이미지가 내포하고 있는 정보 예측
텍스트 요약	T5 모델을 사용하여 콘텐츠 내용을 요약
TTS (Text to Speech)	Vit 모델을 사용하여 텍스트(text)를 음성(speech)으로 변환
이미지 객체 인식	DETR(Detection with Transformer)를 사용하여 이미지 내 객체 인식
OCR (Optical Character Recognition)	TPS-VGG-BiLSTM-Attn을 사용하여 이미지에서 텍스트(text) 추출
검색	text-embedding-ada-002 모델을 사용해 사용자 질문에 대한 Vector DB화를 통해 입력 질문에 대한 유사 질문을 찾아 답변 생성

■ ‘어디답벳’ 모델 프롬프트 진행 방식

- 사용자가 입력한 질문을 세부 과업으로 세분화하여 적절한 세부 모델을 매칭하고 종속성을 결정하는 방식으로 진행되며, 질문에 대한 답변은 세부 모델들의 실행 결과와 사용자 진단 결과에 따른 프롬프트, 응답 생성용 프롬프트를 입력으로 사용하여 사용자 맞춤형 답변을 제공함

- ‘어디답뱃’ 서비스 수행 절차

- ① Task Ordering: 사용자의 요청사항에 따른 Task 정의
- ② Task 세분화 및 모델 선정: 세분화된 Task에 따른 모델 수행 종속성 결정
- ③ 응답 생성 : 각 세부과업(Sub-Task) 모델을 실행하여 중심모델에 결과 전달 후
사용자에게 제공할 응답 생성

2) 자체 모델 개발에 적용할 대표 과업 선정

■ ‘어디답뱃’ 세부 과업(Sub-Task) 중 대표 과업을 선정하여 개발 진행

- ‘어디답뱃’은 다양한 질문 입력 방식에 따른 멀티모달 서비스로, 다양한 세부 모델이 존재함
- 본 연구에서는 사용자의 질문에 대한 정확한 답변을 제공하는 대화형 언어모델을 개발하는 것을 목표로 하고 있어 멀티모달 기능은 적합하지 않은 것으로 판단됨
- 따라서 질문-답변(QA)을 대표 과업(Task)로 선정하여, 대화형에 더 적합한 서울디지털재단 자체 모델을 개발하고자 함


2 모델 개발을 위한 대규모 언어모델의 선정

1) 자체모델 개발을 위한 사전학습 모델 선정

■ 모델 선정 기준에 따른 사전학습 모델 선정

- 자체 모델 개발을 위해서는 공개된 LLM을 사전학습 모델로 사용하여 자체 구축한 데이터를 학습시키고 고도화하는 과정을 수행하여야 함
- 자체 모델 개발은 내부망 서빙이 가능한 오픈소스 기반의 LLM을 활용하여 진행되며, 모델의 추가 학습 및 운영 시에 발생하는 비용을 고려하여 선정

[그림 2-1] 모델에 따른 서빙 비용 비교[6, 재가공]



- 생성형 AI 기반 LLM 의 후보군은 [그림 2-2]와 같으며, 이 중에서도 오픈소스 여부, 서빙 비용, 한국어 답변 성능을 중점적으로 살핀 결과 총 2개의 모델을 선정하여 모델 개발을 진행하였음

① Llama 2 / Llama2-Chat

- Meta의 AI 연구 조직인 Meta AI Research가 2023년 2월 24일에 발표한 대규모 언어모델인 Llama의 두 번째 버전으로 같은 해 7월에 상업용으로 사용 가능하도록 무료 오픈소스로 공개
- OpenAI의 GPT-3보다 파라미터 수가 훨씬 적고, 단위 GPU에서도 동작이 가능하고 벤치마크 테스트의 일부에서는 GPT-3 성능보다 우세
- 파라미터개수 : 70억(7B), 130억(13B), 700억(70B)
- 기존 모델에 비해 훨씬 작은 규모지만, 데이터 학습 강화 및 파인 튜닝 하여 더 큰 규모의 모델과 비교 가능한 효율적인 모델
- Llama2-Chat은 사전 훈련된 모델을 기반으로 반복적으로 강화 학습 및 인간 피드백을 통해 모델을 수행

② Polyglot-ko

- EleutherAI polyglot 연구팀에서 개발한 한국어 거대 모델
- Polyglot에서는 단일 모델에 많은 언어를 한 번에 학습하는 대신 비슷한 어족의 언어를 모아 모델을 학습
- TuNiB AI에서 수집한 1.2TB 규모의 한국어로 학습, 전처리 후 863GB 규모의 데이터가 필터링 됨
- 파라미터개수 : 1.3B, 3.8B, 5.8B, 12.8B
- 현재 Polyglot-ko-v2 개발 중에 있으며, 1.3B부터 다시 학습을 시작하여 최종적으로 40B까지 확장하는 것을 목표로 하고 있음
- Polyglot-ko-v2의 주요 변경 사항 : 기존 비학습된 문학, 교재, 국회의사록, 깃허브 데이터 등의 수준 높은 데이터를 학습 데이터로 추가 및 기존 평가 코드 외의 평가 데이터셋을 다양하게 추가하여 개선

[그림 2-2] 생성형 AI 기반 대규모 언어모델 공개 현황[7]

	PROPRIETARY					
	GPT-1 (110M)	Megatron-LM (8.3B) GPT-2 (1.5B)	Turing-NLG (17B) GPT-3 (175B)	Jurassic-1 (178B) LaMDA (137B)	Chinchilla (70B) Gopher (280B) MT-NLG (530B) PaLM (540B)	GPT-4 (1T)
	OPEN SOURCE					
	ELMo (94M) 2018	RoBERTa (354M) BERT (340M) 2019	T-ELMo (465M) 2020	OPT-175B (175B) GPT-J (6B) 2021	BLOOM (176B) Godel (175B) GPT-NeoX (20B) 2022	LLaMa (65B) 2023

2) 모델 후보별 성능 비교

■ Llama2 GPU 할당량 테스트 수행

- 모델 선정에 앞서 GPU 메모리 사용량에 따른 서버 자원 적용성 판단을 위하여 Llama2 모델을 이용하여 파라미터별 GPU 할당량을 파악하고자 함

- ① Llama2 7B : 약 14~15GB의 메모리를 사용
- ② Llama2 13B : 약 30GB의 메모리를 사용 (GPU 2개 기준 각 15GB)
- ③ Llama2 70B : 약 50GB의 메모리를 사용 (GPU 8개 기준)

[그림 2-3] Llama2 70B GPU 할당량(T4 8개 기준 47.35GB)[8][9]

NVIDIA-SMI 510.47.03				Driver Version: 510.47.03				CUDA Version: 11.6			
GPU	Name	Persistence-M	Bus-Id	Disp.A	Volatile Uncorr. ECC						
Fan	Temp	Perf	Pwr:Usage/Cap	Memory-Usage	GPU-Util	Compute M.	MIG M.				
0	NVIDIA A100-SXM...	On	00000000:C8:00.0	Off	0						
N/A	28C	P0	71W / 400W	14995MiB / 81920MiB	20%	Default	Disabled				
1	NVIDIA A100-SXM...	On	00000000:C8:00.0	Off	0						
N/A	28C	P0	68W / 400W	14995MiB / 81920MiB	20%	Default	Disabled				

[그림 2-4] Llama2 7B GPU 할당량

Processes:							
GPU	GI	CI	PID	Type	Process name	GPU Memory	
	ID	ID				Usage	
0	N/A	N/A	2849	C	/opt/tensorflow/bin/python	12738MiB	
1	N/A	N/A	2849	C	/opt/tensorflow/bin/python	5748MiB	
2	N/A	N/A	2849	C	/opt/tensorflow/bin/python	5748MiB	
3	N/A	N/A	2849	C	/opt/tensorflow/bin/python	5748MiB	
4	N/A	N/A	2849	C	/opt/tensorflow/bin/python	5748MiB	
5	N/A	N/A	2849	C	/opt/tensorflow/bin/python	5748MiB	
6	N/A	N/A	2849	C	/opt/tensorflow/bin/python	5748MiB	
7	N/A	N/A	2849	C	/opt/tensorflow/bin/python	5748MiB	

- 파라미터별 GPU 메모리 할당량 비교 결과, 로컬 모델 사용 시 7B의 경우 24GB, 13B의 경우 40GB 수준, 70B도 50GB 이상의 서버 자원을 보유 시 모델 구동이 가능하다고 판단됨

■ 모델 선정을 위한 후보 모델별 성능 사전 조사

- Llama2의 주요 Benchmarks에 대한 성능 파악
 - ① QA 질의응답 태스크의 경우 7B의 경우 46.9, 13B는 53.0, 70B는 62.0의 정확도를 나타냄
 - ② 13B와 70B의 경우 파라미터 수에 비해 대략 9퍼센트 정도의 적은 차이를 보임
 - ▶ ①과 ②에 근거하여 특정 도메인에 특화된 LLM 개발 시 13B 모델의 경우 Instruction tuning 작업을 통해서 70B 모델만큼의 정확도를 증가시킬 수 있을 것이라 판단됨

[표 2-2] 주요 Benchmarks에 대한 성능 측정 결과[10]

Benchmark	Llama2 (7B)	Llama2 (13B)	Llama2 (70B)
MMLU	45.3	54.8	68.9
TriviaQA	68.9	77.2	85
Natural Questions	23.7	28	33
GSM8K	14.6	28.7	56.8
HumanEval	12.8	18.3	29.9
AGLeval	29.3	39.1	54.2
BoolQ	77.4	81.7	85
HellaSwag	77.2	80.7	85.3
OpenBookQA	58.6	57	60.2
QuAC	39.7	44.8	49.3
Winogrande	69.2	72.8	80.2
Average	47.0	53.0	62.5

- Polyglot-ko 의 주요 Benchmarks에 대한 성능 파악
 - ① COPA(원인·결과 추론), HellaSwag(자연어 이해·상식 추론), BoolQ(참·거짓 판단), SentiNeg(긍·부정 판단) 5개 지표에 대한 파라미터별 성능 조사
 - ② 5개 지표에서 평균적으로 1.3B의 경우 57.0, 3.8B는 56.2, 5.8B는 53.7, 12.8B는 69.6의 평균 정확도를 나타냄
 - ③ 12.8B가 상대적으로 정확도가 높게 나타났을 뿐, 1.3B, 5.8B, 3.8B는 큰 차이를 나타내지 않음
 - ▶ ①, ②, ③에 근거하여 특정 도메인에 특화된 LLM 개발 시 12.8B를 우선으로 채택하되 개발환경이 갖추어지지 못할 경우에는 1.3B, 3.8B를 채택

[표 2-3] Polyglot-ko 파라미터별 성능 측정 결과[11]

Parameter	COPA	HellaSwag	BoolQ	SentiNeg	Average (F-1 Score)
1.3B	0.72	0.525	0.355	0.679	0.56975
3.8B	0.76	0.571	0.432	0.486	0.56225
5.8B	0.775	0.598	0.436	0.339	0.537
12.8B	0.794	0.595	0.482	0.912	0.69575

3) 모델 후보별 파생모델 검토

■ Llama2를 기반으로 한 파생모델 조사 및 검토

- Llama 모델의 경우 사전학습 데이터에 한국어가 제외되어 Full-Finetuning, LoRA, 등의 여러 방법을 통해서 만족스러운 결과를 내지 못함
- Llama2에 있어서 한국어 사전학습 비율은 0.06%([그림 2-5])로 전 세계 인구 중 한국어 화자 비율(1.035%)과 비교하면 크게 낮은 수치임

[그림 2-5] Llama2 모델 각 나라 언어별 사전학습 비율 비교[12]

Language	Percent	Language	Percent
en	89.70%	uk	0.07%
unknown	8.38%	ko	0.06%
de	0.17%	ca	0.04%
fr	0.16%	sr	0.04%
sv	0.15%	id	0.03%
zh	0.13%	cs	0.03%
es	0.13%	fi	0.03%
ru	0.13%	hu	0.03%
nl	0.12%	no	0.03%
it	0.11%	ro	0.03%
ja	0.10%	bg	0.02%
pl	0.09%	da	0.02%
pt	0.09%	sl	0.01%
vi	0.08%	hr	0.01%

- 최근 Llama2를 백본(Backbone)으로 한 한국어 기반 오픈소스 사전학습 모델이 개발되고 있음
- 그 중, 개발 시점에서 한국어 기반 모델 중 가장 많은 사용자(6.41k)를 확보하고 있는 모델인 Llama-2-ko-7b-Chat의 사용성에 대하여 검토하고자 함

■ Llama2-ko-7b-Chat의 개요

- Llama2-ko-7b-Chat 모델의 학습 데이터셋, 프롬프트 양식 등의 내용은 [표 2-4]와 같음

[표 2-4] Llama2-ko-7b-chat 모델 소개

구분	주요내용
사전학습 데이터 셋	• nlpai-lab/kullm-v2
Backbone Model	• llama2 7b
Prompt 템플릿 양식	• kullm
모델 출처	• https://huggingface.co/kfkas/Llama-2-ko-7b-Chat

- Llama-2-ko-7b 모델의 경우 MIT 라이선스를 따르고 있어 수정 및 배포가 자유로우며, 실무 및 상업적으로 자유롭게 사용이 가능하나, 월간 이용자 700만 명 이상인 경우, 메타에게 라이선스를 요청해야 함


[표 2-5] Llama2-ko-7b-chat License 관련 주요 내용[13]

구분	주요내용
라이선스 권리 및 재배포	• Llama 자료 배포 시 해당 계약서를 제3자에게 제공. • Llama 자료를 다른 언어 모델 개선에 사용 금지. • 모든 Llama 자료 복사본에 저작권 고지 필요.
상업적 조건	• 월 700백만 이상의 사용자가 있을 경우 Meta로부터 별도의 라이선스 요청 필요.
보증의 부인	• Llama 자료와 그 결과는 "있는 그대로" 제공. 사용자가 사용 및 재배포에 대한 책임짐.
지적 재산권	• 라이선스에 상표 사용 권한은 포함되지 않음. • Llama 자료의 파생작과 수정에 대한 권리는 사용자에게 있음.
기관사용 시 고려해야 할 라이선스 내용	
소프트웨어는 "AS IS" 상태로 제공되며, 어떠한 보증도 없습니다. 또한, 개발자가 700만 이상의 월간 활성 사용자를 가지는 경우 추가 상업적 조건이 적용 되며, 이 라이선스를 준수해야 합니다. 지적재산권 및 책임 제한 등의 내용도 포함됩니다. 이 라이선스는 캘리포니아 주의 법률에 따라 규정되며, 관련 분쟁은 캘리포니아의 법원에서 해결됩니다.	

■ Polyglot-ko를 기반으로 한 파생모델 조사 및 검토

- 백본(Backbone) 모델로 Polyglot-ko 12.8B를 사용한 파생모델인 KULLM(구름)은 고려대학교 NLP & AI 연구실과 HIAI 연구소가 개발한 한국어 LLM임
- GPT4ALL, Dolly, Vicuna 데이터셋을 deepl을 이용해 번역하여 만든 데이터셋으로 학습을 진행하였으며, 기존에 공개된 한국어 LLM(KoAlpaca, KoVicunna) 대비 높은 성능을 보임

[그림 2-6] KULLM 성능 평가결과[14]



KULLM의 개요

- KULLM은 apache2.0 라이선스를 따르고 있어 상업적으로 자유롭게 사용이 가능

[표 2-6] KULLM License 관련 주요 내용[15]

구분	주요내용
사전학습 데이터셋	- Polyglot-ko 5.8B 기반-v2: GPT-4-LLM, Dolly, Vicuna - Polyglot-ko 12.8B 기반-v2: GPT-4-LLM, Dolly, Vicuna
Backbone Model	Polyglot-ko
Prompt 템플릿 양식	kullm
모델 출처	https://github.com/nlpai-lab/KULLM
기관사용 시 고려해야 할 라이선스 내용	
소프트웨어와 작업을 수정하여 배포하는 경우에는 몇 가지 조건을 준수해야 합니다. 이러한 조건에는 라이선스 복사본을 제공하고 수정한 파일에 변경 사항을 명시하는 것, 소스 형식에서 해당 작업물의 모든 저작권, 특허, 상표 및 표시 공지 사항을 보존하는 것, 그리고 "NOTICE" 텍스트 파일을 포함하여 필요한 공지 사항을 유지하는 것이 포함됩니다.	

파생모델 미세조정 결과 분석 및 비교

- 모델의 선정을 위하여 파생모델의 Instruction tuning과 LoRA 적용을 통한 미세조정(Fine-tuning)을 실시하고 결과에 대한 분석을 수행하였음
 - 미세조정(Fine-tuning) 기법
 - ① Instruction tuning
 - LLM은 기본적으로 다음 단어 예측 시 사용자 의도가 아닌 가장 자연스러운 확률의 단어를 택하며 이는 사용자 의도에 맞지 않은 경우의 발생 가능성이 존재함

- Instruction tuning은 LLM이 사용자의 의도에 맞는 답변을 주기 위한 학습 방법으로, Instruction(지시문)과 input text, output text의 pair 데이터셋을 이용하여 지도(supervised) 학습 방식으로 ‘어디답뵓’ QA데이터셋의 최적화하여 적용하였음

② LoRA(Low-Rank Adaptation)

- 큰 모델일수록 사전 학습 후에 Fine-tuning 수행 시 많은 파라미터를 학습시켜야 하기 때문에 오랜 시간과 더불어 비효율성이 발생
- LoRA는 사전 훈련된 모델 가중치를 고정시키고 랭크 분해 행렬을 사용하여 학습 가능한 파라미터 수를 줄여 GPU 사용을 효율적으로 할 수 있는 방식임
- 실제로 파라미터 수를 적게 학습했음에도 불구하고 기존 모델만큼의 정확도를 보이는 연구 결과를 보임

[그림 2-7] LoRA 방식을 사용한 정확도 측정 결과[16]


Model&Method	# Trainable Parameters	WikiSQL	MNLI-m	SAMSum
		Acc. (%)	Acc. (%)	R1/R2/RL
GPT-3 (FT)	175,255.8M	73.8	89.5	52.0/28.0/44.5
GPT-3 (BitFit)	14.2M	71.3	91.0	51.3/27.4/43.5
GPT-3 (PreEmbed)	3.2M	63.1	88.6	48.3/24.2/40.5
GPT-3 (PreLayer)	20.2M	70.1	89.5	50.8/27.3/43.5
GPT-3 (Adapter ^H)	7.1M	71.9	89.8	53.0/28.9/44.8
GPT-3 (Adapter ^H)	40.1M	73.2	91.5	53.2/29.0/45.1
GPT-3 (LoRA)	4.7M	73.4	91.7	53.8/29.8/45.9
GPT-3 (LoRA)	37.7M	74.0	91.6	53.4/29.2/45.1

③ 미세조정 시 사용한 학습파라미터 값


[표 2-7] Fine-tuning 파라미터 값

Parameter	value	parameter 설명
Batch Size	16	1회 연산에 사용되는 동시에 처리하는 데이터 샘플의 총 수
micro_batch_size	2	1회 연산 시 처리하는 데이터 샘플의 가장 작은 단위
LoRA Rank	64	모델의 임베딩 차원 수
LoRa Alpha	128	모델의 특정 부분 재학습 결정 파라미터 값
lora_dropout	0.05	레이어 생략 비율
epochs	5	전체 데이터셋에 대한 반복 학습 수

- 기본 QA 데이터셋을 이용한 파생모델별 미세조정 비교 결과, 첫 번째로 응답 생성 시 end token 제한이 없어 답변이 길어지고 반복하는 문제가 발생하였음
 - ▶ 응답 생성 시 end token 제한이 없어 답변이 길어지는 문제가 있으나 앞부분의 답변 부분은 test set의 output과 일치하는 답변이 생성



- 두 번째로 KULLM의 경우 답변 요지에서 벗어난 응답문 생성하는 경향을 보임



- 모델 결과 문제점의 해결방안으로 파라미터 수정과 Instruction 수정을 제안하여 차후 모델링 방법을 설계하였음
 - 파라미터 수정
 - end token 길이 제한을 통한 응답문의 생성 제한
 - test dataset에 fitting 되도록 epoch 조정(10epoch 이상)
 - Instruction 템플릿 변형
 - Instruction 제시 시 “질문에 맞는 답을 생성하여라” 대신, 요지에 “질문에 맞는 핵심적인 답변을 생성하여라” 등으로 요구사항의 구체화 및 글자 수 제한의 지시문 추가 등의 프롬프트 설계

4) 최종 개발 모델 선정

■ 최종 모델 선정을 위한 파생모델별 답변 품질 비교

- 본 연구와 연계된 과업에서 구축한 QA셋 데이터⁴⁾를 활용한 미세조정 후의 결과를 비교하였음
 - ① 구조화된 답변 제공 여부
 - Llama2-ko-chat이 KULLM 대비 더 세부적이고 절차적인 답변을 제공


[표 2-8] Llama2-ko-chat와 KULLM 의 세부적인 답변 제공 여부 비교

예시답변 항목	Llama2-ko-7b-chat output	KULLM 5.8b output
카카오 맵에서 버스 도착 정보 확인 방법	화면에 정보 뜨는 방식 설명, 버스 번호 및 정류장 이름 확인 방법 제공	주변 정류장과 버스 정보 제공, 실시간 위치 확인 가능성 언급 (직접적인 방법은 제공하지 않음)
앱 삭제 후 재설치 방법	앱 삭제 가능성 언급, 삭제 후 재 다운로드 필요성 설명	앱 관리 방법 언급 (직접적인 삭제 및 재설치 방법은 제공하지 않음)
어제 찍은 사진 확인 방법	설정화면 접근 방법 제공, 앨범 접근하여 사진 확인 방법 제공	갤러리 및 동영상 확인 방법 언급 (직접적인 사진 확인 방법은 제공하지 않음)

- KULLM은 주제에 대한 일반적인 정보나 맥락을 설명하는 경향이 있으나, 구체적인 단계별 해결책을 제공하지 않음. 반면에 Llama2-ko-chat는 질문에 대한 구체적인 단계별 해결책을 제공하며, 사용자의 요구에 좀 더 정확하게 응답하는 경향이 있음.

4) 서울디지털 재단 연구보고서 「LLAMA-SDF 기반 어르신 디지털 상담 챗봇 파이프 라인 구축」 참고

[그림 2-8] Llama2-ko-chat 와 KULLM 간의 세부적인 내



② 단어 풍부도 비교

- Llama2-ko-chat이 KULLM 대비 더 풍부한 단어 정보를 제공하고 있음
- 랜덤샘플 추출 후 비교 결과 약 Llama2-ko-chat은 60개, KULLM은 35단어로 Llama2-ko-chat이 약 1.7배 정도 많이 생성함([표 2-9])

[표 2-9] Llama2-ko-chat와 KULLM 간의 답변 풍부도 비교

Llama2-ko-7b-chat		KULLM 5.8b	
output	Word Count	output	Word Count
주의하실 점은 이 앱은 무료지만, 데이터 소모량이 크기 때문에 와이파이 환경에서 사용하시는 것을 추천드립니다. 다운로드한 파일은 스마트폰의 SD카드에 저장됩니다. 다시 보려면 플레이스토어나 원스토어를 통해 해당 앱으로 들어가시면 되고요. 검색창에 원하는 제목이나 키워드를 검색하시면 관련 영상을 쉽게 찾으실 수 있습니다.	63	이렇게 해서 다운받은 영상의 저장 위치로 이동하면 됩니다. 여러분들께서 이 앱을 사용함으로써 어르신들이 좀 더 편리하고 유익한 정보 생활을 할 수 있기를 기대해 봅니다. 지금까지 스마트폰 활용 교육에서 배운 내용으로 어르신께 직접 전화해서 확인해보세요	39
sd카드를 빼고 다시 꼽아주시면 됩니다. 그리고 나서 플레이스토어를 열고 원하시는 앱이나 게임들을 다운로드하시면 됩니다. 이렇게 하면 스마트폰의 용량이 커졌기 때문에 더 이상 사진과 동영상, 오디오 파일 등을 찍거나 다운 받을 수 있게 되는 것이지요. 참 쉽죠 이럴 때 사용해 보면 정말 내 스마트폰은 왜 그렇게 느린지 모르겠다고 생각하실 때가 있으실 겁니다.	58	이제부터 스마트폰에서 사용 가능한 기능들 중 자주 활용하고 많이 쓰시는 몇 가지 기능들을 배워보도록 하겠습니다. 먼저 홈 화면의 맨 아래에 있는 설정 앱으로 들어가십니다. 쪽 내리다 보면 휴대폰 정보라는 것이 보이실 겁니다.	30

Llama2-ko-7b-chat		KULLM 5.8b	
output	Word Count	output	Word Count
국세청에서 자동납부 신청이 되었다는 문자가 오게 됩니다. 그때에 본인인증만 해주시면 바로 세금납부가 가능하게 되는 것이죠 이렇게 하면 연말정산 때 따로 영수증을 챙기지 않으셔도 되고요 또 나중에 환급받을 때도 편리하고 또 이 연동 서비스로 다른 공과금들도 한꺼번에 처리할 수 있습니다. 오늘은 이렇게 연말정산을 위한 홈택스 이용방법과 세액 공제를 받는 방법을 소개했습니다.	58	국세나 지방세 등의 고지서가 우편으로 오면 어떻게 해야 할까요? 바로 전자고지로 해결하면 됩니다. 내야 할 세금도 자동적으로 알아서 계산되어서 나옵니다. 또한, 은행에서 직접 방문해서 창구로 가실 필요 없이 인터넷뱅킹이나 스마트폰 뱅킹 앱만 설치해 두시면 됩니다.	36

③ 원본 답변과의 정확도 비교

- KULLM은 원본 답변의 주제를 일부 포착하지만 세부 정보에서 약간 벗어나는 경향을 보임
- 전반적으로 Llama2-ko-chat와 KULLM 모델 모두 원본 답변의 모든 내용을 완벽하게 반영하지는 않으나, Llama2-ko-chat이 세부 정보와 추가 기능 설명에서 더 나은 일치성을 보인다고 판단됨

[표 2-10] Llama2-ko-chat와 KULLM 간의 정확도 비교(랜덤 샘플 추출)

원본 데이터셋 내용	Llama2-ko-7b-chat	KULLM 5.8b
버스 도착 정보 제공	부분적 일치 (버스 정보 표시 및 사용법 안내)	일부 일치 (위치와 버스 정보 제공 언급)
버스 번호 및 도착 시간	일치 (버스 번호 및 정류장 표시)	부분적 일치 (주변 정류장 및 버스 정보)
앱 삭제 및 재 다운로드 가능성	부분적 일치 (앱 삭제 언급)	일치 (앱 삭제와 재 다운로드 가능성 안내)
사진 및 동영상 관리	일치 (사진 및 동영상 기능 설명)	부분적 일치 (동영상 기능 설명)

■ 최종 모델 선정

- 전반적인 성능 평가 결과, ‘Llama2-ko-chat’ 모델이 더 세부적이고 절차적인 답변을 제공하는 경향이 있다고 판단됨
- Llama2-ko-chat 모델은 특히 다단계 추론이 필요한 질문에 대해 더 정확하고 구체적인 답변을 제공할 수 있는 장점이 있음
- 이에 서울디지털재단 자체 모델 개발을 위한 사전학습 모델로서 Llama2-ko-chat (7B)

모델을 최종 모델로 선정함

[표 2-11] Llama2-ko-chat와 KULLM 모델 최종 비교

비교 기준	Llama2-ko-7b-chat	KULLM 5.8b	분석 내용
구조화된 답변 제공 여부	일반적인 정보 제공	세부적이고 절차적인 답변 제공	Llama2-ko-chat은 KULLM에 비해 좀 더 구체적이고 단계별 해결책을 제공, 사용자의 요구에 더 정확하게 응답함
단어 풍부도	약 35단어	약 60단어	Llama2-ko-chat은 단어의 다양성과 풍부함에서 KULLM보다 약 1.7배 더 많은 단어를 사용, 표현력이 풍부함
원본 답변과의 정확도	주제 일부 포착, 세부 정보에서 벗어남	세부 정보와 추가 기능 설명에서 더 나은 일치성	두 모델 모두 완벽한 일치성은 아니지만, Llama2-ko-chat이 원본 답변의 세부 요소와 기능에 대해 더 정확하고 상세한 정보를 제공

3 모델 개발 및 성능 고도화 작업

1) 모델 개발 프로세스

■ 모델 성능 고도화 방안 선정 및 적용에 대한 검토 수행

- 모델의 성능을 고도화할 수 있는 다양한 방법 중 적용 가능한 방안을 선정하여 최적화하는 작업을 수행하고자 함
- 모델의 성능 향상을 위한 고도화 방안은 크게 Pre-training, Fine-tuning, In-context Learning으로 구분되며, 세 가지 고도화 방안은 학습(Learning), 프롬프트(Prompt), 메모리(memory)에 따라 각각 다르게 수행이 됨([그림 1-3])

① Pre-training

- Pre-training이란 기존 임의의 값으로 초기화된 모델의 가중치들을 다른 작업(task)에 학습시킨 가중치들로 초기화하는 방법을 말함[17]
- 이 경우 다음 토큰을 예측하는 방식으로 진행되므로, self-supervised learning이라 할 수 있으며[5], 주로 parametric memory를 심는 과정이라 할 수 있음

② Fine-tuning

- Fine-tuning이란 사전학습한 모든 가중치와 더불어 최소한의 가중치를 추가하여 모델을 추가 학습(미세조정)하는 방법을 말함[17]
- Fine-tuning의 경우 학습(Learning)에서는 Instruction fine-tuning, Reinforcement

Learning with Human Feedback(RLHF)로 크게 나눌 수 있고, 두 과정에서 PEFT (Parameter Efficient Fine-Tuning) 기법을 통한 가중치를 고정된 학습이 가능함

- Fine-tuning의 프롬프트(Prompt)는 모델에서 전달하는 질문이나 요청을 사용자가 응답을 유도(prompt)하게 만드는 과정임

③ in-context learning

- in-context learning은 프롬프트의 맥락적 의미(in-context)를 이해하여 모델의 답변을 생성하는 것을 의미하며, 이 과정에서는 별도의 모델 학습은 진행되지 않음[18]
- 주어지는 모델의 예시에 따라 zero-shot, one-shot, few-shot으로 나뉘며, 이는 각각 예시의 수에 따른 작업(task)을 의미함

④ 메모리(Memory)

- 메모리는 가중치(weight)와 편차(bias)에 저장되는 값을 기반으로 하는 기억의 형태로, LLM의 경우 추론에서 생성되는 형태를 의미함[19]
- parametric memory와 non-parametric memory로 구분되며, parametric memory는 pre-train과 fine-tuning의 가중치 업데이트 과정에서 학습되는 내용을 의미하며 추론으로 화상하는 과정이라 할 수 있고, non-parametric memory는 프롬프트의 내용에 기반한 non-parametric reference의 발현이라 할 수 있음[5]

■ 모델 성능 고도화 방안 선정

- 세 가지 고도화 방안(Pre-training, Fine-tuning, In-context Learning)에서 본 연구에 적용 가능한 고도화 방안을 선정하고자 함
- Pre-training은 개발의 새로운 대규모 언어모델을 개발하는 과정으로, 대용량의 데이터셋의 구축과 모델 서빙 비용, 많은 전문 인력을 필요로 하는 작업인데, 현재의 과업의 특성과 목적에 부합하지 않아 배제하였음
- Fine-tuning에의 경우 Pre-training을 통해 새로운 모델을 개발하는 것보다 훨씬 적은 리소스 및 비용으로도 가능하기 때문에 본 연구에서는 Fine-tuning 고도화 방안을 채택하고자 함
- 본 연구에서 채택한 고도화 방안은 Instruction fine-tuning, Reinforcement Learning with Human Feedback(RLHF), Adapter이며, 추가로 few-shot prompt learning도 적용하고자 함

2) 고도화 방안 1 - Instruction tuning

■ Instruction tuning 적용을 통한 모델 성능 고도화 작업

- Instruction tuning이란 LLM이 사용자의 의도에 맞는 답변을 주기 위한 학습 방법임
- 본 연구에서는 Instruction(지시문)과 input text, output text의 pair 데이터셋을 통한 supervised 형식의 학습을 진행하였고, 이를 위해 최적화된 QA 데이터셋을 사용하였음
- SFT(Supervised Fine-Tuning) 데이터셋의 경우 구축된 Prompt와 Response 스타일에 따른 학습이 진행되었음

[그림 2-9] SFT(Supervised Fine-Tuning) 데이터셋 예시

```

instruction, input, output, text
질문에 맞는 답을 생성하여라, 회의 예약을 하려는데 어떻게 해야하나요?, "예약하기를 누르시면, ""다음""이라는 버튼이 나옵니다. 그것을 눌러주세요! 그러면 다양한 옵션들이 나타날텐데요, 원하시는대로 선택하시면 됩니다. 그리고 완료 버튼을 누르면 예약이 진행되고 화면에 예약 정보가 표시될 것입니다. 이제부터 해당 회의를 이용하실 수 있습니다. 즐거운 시간 되세요~! 감사합니다 :) [추가설명] 예약하기 버튼은 일반적으로 홈페이지의 오른쪽 상단에 위치합니다. 또한, 예약한 후에도 언제든지 취소할 수도 있으니 걱정하지 마", "아래는 작업을 설명하는 명령어와 추가 컨텍스트를 제공하는 입력이 짝을 이루는 예제입니다. 요청을 적절히 완료하는 응답을 작성하세요.

### 명령어: 질문에 맞는 답을 생성하여라
### 입력: 회의 예약을 하려는데 어떻게 해야하나요?
### 응답: 예약하기를 누르시면, ""다음""이라는 버튼이 나옵니다. 그것을 눌러주세요! 그러면 다양한 옵션들이 나타날텐데요, 원하시는대로 선택하시면 됩니다. 그리고 완료 버튼을 누르면 예약이 진행되고 화면에 예약 정보가 표시될 것입니다. 이제부터 해당 회의를 이용하실 수 있습니다. 즐거운 시간 되세요~! 감사합니다 :) [추가설명] 예약하기 버튼은 일반적으로 홈페이지의 오른쪽 상단에 위치합니다. 또한, 예약한 후에도 언제든지 취소할 수도 있으니 걱정하지 마"
질문에 맞는 답을 생성하여라, "전화와 와도 소리가 안들리네요, 벨 소리를 어떻게 조정해야하나요?", "벨 소리를 변경하고 싶으시다면, ""소리""라는 항목을 찾아보세요! 거기서 다양한 소리로 설정할 수 있습니다. 또한, 진동 모드에서도 마찬가지로 ""스피커 모양""이라는 버튼이 있는데요, 그곳을 누르시면 스피커 모양의 아이콘으로 바뀝니다. 이렇게 하면 더 쉽게 벨 소리를 조절하실 수 있게 되고! 그리고 마지막으로, ""알림음""이라고 적힌 부분을 찾아서 원하시는 알림음을 선택하시면 됩니다. 이러한 방법으로 편리하게 벨 소리를 바꿀 수 있답니다! 그럼", "아래는 작업을 설명하는 명령어와 추가 컨텍스트를 제공하는 입력이 짝을 이루는 예제입니다. 요청을 적절히 완료하는 응답을 작성하세요.


```

■ Instruction tuning 적용 결과 분석

- Llama-ko-chat 모델에 대하여 데이터셋에 따른 미세조정을 실시하였고, 입력된 질문에 대한 생성된 답변과 테스트셋(test set)⁵⁾의 결과를 비교하였음
- 비교 결과 모델 생성 시 end token의 제한이 없어 응답의 길이가 길어지는 문제가 발생하였고 동일한 내용을 반복하는 repetition 문제가 발생

5) 테스트셋(test set) : 학습 데이터셋의 일부 데이터를 선별한 데이터셋으로, 모델 성능 검증을 위해 사용됨. 이 과정에서 테스트셋의 데이터셋 분포가 학습 데이터셋 분포와 일치한다는 가정이 필요[20]

[그림 2-10] Llama2-ko-7b-chat의 생성문과 테스트셋 비교




- 그러나 답변의 내용의 경우 테스트셋과 일치하는 결과를 보이므로, 파라미터 수정 및 instruction 변형을 통해 문제를 해결하였고([그림 2-11]), 문장의 끝맺음의 경우 차후에 EOS token 적용을 통해 해결하였음

- (개선 방안) 모델 파라미터 조절

- max_new_tokens(생성되는 최대 토큰 수 설정), repetition_penalty(반복 답변 통제 변수) 등 모델 파라미터 조절
- temperature 값을 기존보다 좀 더 낮게 하여(0.8에서 0.5) 변경 전 대비 질의응답 시 보다 간결한 응답이 생성되도록 하여 맥락에 맞는 답을 생성하는 확률 커짐

[그림 2-11] max_new_tokens, repetition_penalty 파라미터 조절 결과



[표 2-12] Llama2-ko-chat 파라미터 변경 사항

Parameter	value
epochs	10
Batch size	16
learning rate	3e-4
LoRA Rank	32
LoRA Alpha	64
temperature	0.5

- 더 나아가, 기존의 학습 데이터셋의 경우 단일 발화에만 적용되는 한계가 있어 다회턴(History) 대화셋에 대한 fine-tuning 작업도 추가로 수행하였음
- 다회턴(History) 기반으로 fine-tuning된 모델은 기존 모델에 비해 질문에 대한 이해도가 복잡하거나 다양한 맥락을 포함한 질문에 대한 응답 능력이 개선된 것을 확인하였음

3) 고도화 방안 2 - Prompt learning


■ Prompt learning 적용을 통한 모델 성능 고도화 작업

- Prompt learning이란 LLM을 전달하는 질문이나 요청을 사용자가 응답을 유도(prompt)하는 방법을 말함
- Prompt learning의 경우 다양한 방식이 존재하나, 예시 및 사고 기반의 학습 방법으로 나눌 수 있음

[그림 2-12] 예시 기반 prompt learning 방식[22]



[그림 2-13] 사고 기반 prompt learning 방식[22]



- 예시 기반은 zero/one/few-shot과 같이 프롬프트에 예시를 주고 예시와 같은 답변을 생성하도록 하는 방식이며, 사고 기반은 LLM에게 답변에 대해 ‘추론’하도록 요청하는 방식으로, 생각을 더 작은 단계로 나누게 함으로써 각 단계에 더 많은 계산을 제공함
- 본 연구에서는 예시 기반과 더불어 사고 기반의 CoT(Chain of Thought) 방안을 채택하여 prompt learning을 수행하였음
- CoT는 연쇄프롬프트라고도 하며, LLM에게 절차를 세부적으로 명시하여 정한 순서에 따라 문제를 풀도록 유도하는 방식으로 LLM이 문제를 쪼개어 해석하여 생각을 연쇄적으로 풀이해 나가며 그 정확성을 높이는 방안 중 하나임
- 선행 연구에 따르면 단계별 추론을 요하는 산술 작업에서는 Basic Prompt는 17.7%이며, CoT를 한 경우 78.7%로 정확도가 월등히 향상되었음[21]
- CoT 기법은 instruction과 input에 각각 적용하여 결과를 비교하였음

① Instruction에 CoT 프롬프트 적용

- Instruction에 “단계별로 나누어”라는 절차를 요하는 답변을 추가하여 단계별로 답변을 받을 수 있도록 하였음.


[그림 2-14] Instruction에 CoT 방법 적용



② Input에 CoT 프롬프트 적용

- Input에 “단계별로 나누어”라는 절차를 요하는 답변을 추가하여 단계별로 답변을 받을 수 있도록 하였음.

[그림 2-15] Input에 CoT 방법 적용



■ Prompt learning 적용 결과 분석

- 예시 기반의 Basic 프롬프트와 CoT 프롬프트 결과 비교

① Instruction에 CoT 기법 적용 결과

- 방법이나 기능을 요하는 답변을 하는 경우 CoT 프롬프트를 통해 구체적인 방법에 대한 답변을 제공하는 점이 Basic 프롬프트와 차이를 보임

[표 2-13] Instruction 항목에 CoT 기법 적용 결과 예시

input	Output(Basic)	Output(CoT)
카카오버스 앱을 처음 쓰려는데 어떻게 회원가입을 해야 하나요?	먼저, 카카오버스를 이용하기 위해서는 먼저 회원가입을 하셔야 합니다! 회원가입은 매우 간단하니 걱정하지 마세요 :)	먼저, 카카오버스를 이용하기 위해서는 먼저 회원가입을 하셔야 합니다! 회원가입은 매우 간단하니 걱정하지 마세요. 우선, "앱 다운로드" 버튼을 누르시고, 설치된 어플리케이션에서 '계정 만들기'나 '로그인' 메뉴를 선택하시면 됩니다. 그리고 나서 필요한 정보를 기입하시고, 인증절차를 거치면 간편하게 회원이 되실 수 있습니다. 이제부터는 편리하고 쉽게 카톡과 연동하여 버스정보도 받아보고, 예약 및 탑승까지 가능해집니다. 즐거운 여행이 되길 바랍니다! (구체적 방법 명시)

input	Output(Basic)	Output(CoT)
내가 갤러리에서 사진을 가져와서 편집하려고 하는데 스타일을 선택할 수 있는 기능을 모르겠어. 어떻게 하면 되지?	갤러리에 들어가서 사진편집하기를 누르시면, 아래쪽에 다양한 스타일들이 나열되어 있습니다. 원하시는 스타일로 변경하시면 됩니다!	갤러리에 들어가서 사진편집하기를 누르시면, 다양한 스타일들이 뜹니다! 원하시는 스타일로 변경하시면 됩니다. 선택하신 후에 오른쪽 상단에 있는 "적용" 버튼을 눌러 주시면 됩니다. 이렇게 하면 편리한 방법으로 사진을 꾸밀 수 있습니다!(구체적 방법 명시)
네이버 앱에서 글자를 크게 보는 방법은 어떻게 되나요?	글자가 작아서 불편하신가요? 그렇다면, 네이버 앱에서는 '돋보기' 기능으로 큰 글자로 볼 수 있습니다! 이 기능은 네이버 앱의 왼쪽 상단에 있는 세 줄 메뉴에 포함되어 있어요.	글자가 작아서 불편하신가요? 그렇다면 네이버 앱에서는 "돋보기" 기능으로 큰 글자로 볼 수 있습니다! 이 기능은 네이버 앱의 왼쪽 상단에 있는 3개의 줄로 된 버튼 중에서 가장 오른쪽에 있는 것을 누르시면 됩니다. 그러면 돋보기를 선택할 수 있어요. 이렇게 하면 작은 글자도 쉽게 읽을 수 있습니다!(구체적 방법 명시)
유튜브에 비디오 올리려면 어떻게 해야 해?	유튜브에서 동영상을 올리고 싶으시다면, 먼저 유튜브 계정을 만들어야 합니다! 계정만들기부터 시작해서 다양한 기능들을 배워보세요.	유튜브에서 동영상을 올리고 싶으시다면, 먼저 유튜브 사이트나 앱으로 들어가셔야 합니다. 그리고 '업로드' 버튼이나 메뉴를 찾아 클릭하시면 됩니다! 동영상의 종류(예시로는 오디오 또는 이미지)도 선택할 수 있으니 원하시는 형식으로 업로드를 진행해주세요.(구체적 방법 명시)
마이크로 SD 카드를 스마트폰에 넣는 방법은 어떻게 되나요?	스마트폰에서 마이크로 SD카드는 보통 옆면에 위치하고 있습니다. 마이크로 SD카드가 잘 있는지 확인해 보시고, 만약 없다면 근처의 대형마트나 전자제품매장에서 구매하실 수 있습니다!	스마트폰에서 마이크로 SD카드를 삽입하려면, 먼저 휴대폰의 뒷면을 열고 배터리커버를 분리해주세요. 그리고 그 안에 있는 유심카드 트레이를 찾아주세요. 유심카드 트레이 근처에는 보통 작은 구멍이 있는데요, 그곳을 통해 마이크로 SD카드가 들어갈 수 있습니다. 마이크로 SD카드를 해당 위치에 넣고 다시 뚜껑을 닫아주시면 됩니다!(구체적 방법을 단계별로 명시)

② Input항목에 CoT기법 적용 결과

- Instruction 부분과 마찬가지로 방법이나 기능을 요하는 답변의 경우 CoT 프롬프트를 통해 구체적인 방법에 대한 답변 제공하는 점이 기존 Basic Prompt 방식과 차이가 있었음.

[표 2-14] Input 항목에 CoT기법 적용 결과 예시

input(Basic)	Output(Basic)	input(CoT)	Output(CoT)
카카오버스 앱을 처음 쓰려는데 어떻게 회원 가입을 해야 하나요?	먼저, 카카오버스를 이용하기 위해서는 먼저 회원가입을 하셔야 합니다! 회원 가입은 매우 간단하니 걱정하지 마세요 :)	카카오버스 앱을 처음 쓰려는데 단계별로 어떻게 회원 가입을 해야 하나요?	먼저, 카카오버스를 이용하기 위해서는 먼저 회원가입이 필요합니다. 1단계로 '앱 다운로드' 버튼을 누르시고, 2단계에 따라 안내되는 절차에 따라 회원가입을 진행하시면 됩니다.(구체적 방법 명시)

input(Basic)	Output(Basic)	input(CoT)	Output(CoT)
내가 갤러리에서 사진을 가져와서 편집하려고 하는데 스타일을 선택할 수 있는 기능을 모르겠어. 어떻게 하면 되지?	갤러리에 들어가서 사진 편집하기를 누르시면, 아래쪽에 다양한 스타일들이 나열되어 있습니다. 원하시는 스타일로 변경하시면 됩니다!	내가 갤러리에서 사진을 가져와서 편집하려고 하는데 스타일을 선택할 수 있는 기능을 모르겠어. 단계별로 어떻게 하면 되지?	갤러리에 들어가서 사진편집하기를 누르시면, 다양한 스타일들이 뜹니다. 원하시는 스타일로 변경하고 싶으시다면, 아래에 보이는 "스타일"이라는 부분을 터치하시면 됩니다. 그러면 여러 가지 옵션이 나열되어 있는데요, 그중에서 마음에 드는 것을 골라주시면 됩니다! (구체적 방법 명시)
네이버 앱에서 글자를 크게 보는 방법은 어떻게 되나요?	글자가 작아서 불편하신가요? 그렇다면, 네이버 앱에서는 '돋보기'기능으로 큰 글자로 볼 수 있습니다! 대이 기능은 네이버 앱의 왼쪽상단에 있는 세줄 메뉴에 포함되어 있어요.	네이버 앱에서 글자를 크게 보는 방법은 단계별로 어떻게 되나요?	글자가 작아서 불편하신가요? 그렇다면, 네이버 앱에서는 3가지 방법으로 글자크기를 조절할 수 있습니다. 첫 번째로, 화면 상단의 '돋보기 아이콘'이나 하단좌측의 '더 보기메뉴', 우측에 있는 '공유' 아이콘 중 하나를 선택하시면 됩니다. 그러면 다양한 옵션들이 나타날텐데요, 그중에서 "글자 크게" 또는 "글자 작게", "돋보기로 읽기" 등과 같은 기능들을 선택하실 수 있을 거예요. 이렇게 하면 원하시는 대로 글자의 크기가 커지거나 작아집니다! (구체적 방법 명시)
유튜브에 비디오 올리려면 어떻게 해야 해?	유튜브에서 동영상을 올리려고 하시다면, 먼저 유튜브 계정을 만들어야 합니다! 계정 만들기부터 시작해서 다양한 기능들을 배워보세요.	유튜브에 비디오 올리려면 단계별로 어떻게 해야 해?	먼저, 유튜브 계정을 만드신 후 '내 프로필'메뉴로 들어가세요. 그리고 오른쪽 상단에 있는 "업로드"버튼을 클릭하시면 됩니다. 그 다음에는 업로드 할 동영상의 제목과 태그(키워드)를 설정하고, 설명이나 이미지 등을 첨부해주세요. 마지막으로 영상파일을 선택하신 후 "확인"버튼을 누르시면 됩니다. 이렇게 하면 여러분의 멋진 영상을 다른 사람들에게도 공유하실 수 있습니다! (구체적 방법 명시)
마이크로 SD 카드를 스마트폰에 넣는 방법은 어떻게 되나요?	스마트폰에서 마이크로 SD카드는 보통 옆면에 위치하고 있습니다. 마이크로 SD카드가 잘 있는지 확인해 보시고, 만약 없다면 근처의 대형마트나 전자제품매장에서 구매하실 수 있습니다!	마이크로 SD 카드를 스마트폰에 넣는 방법은 단계별로 어떻게 되나요?	스마트폰에서 마이크로 SD카드를 삽입하려면, 먼저 전원버튼과 볼륨키 사이에 있는 작은 구멍이 있습니다. 그곳을 통해 카드의 핀을 밀어 넣으면 됩니다. 그리고 나서, SD카드가 정확하게 위치했는지 확인하고, 다시 한 번 눌러주시면 됩니다. 이렇게 하면 쉽게 마이크로 SD카드를 스마트폰에 장착할 수 있습니다! (구체적 방법 명시)

③ Instruction과 input 항목에 CoT기법 적용 결과

- Instruction 부분이나 input 중 1개에만 CoT 기법을 적용한 것처럼 2개 항목 모두 CoT 기법을 적용한 결과도 구체적인 답변을 얻음

[표 2-15] Instruction과 input 항목에 CoT 기법 적용 결과 예시


input(Basic)	Output(Basic)	input(CoT)	Output(CoT)
카카오버스 앱을 처음 쓰려는데 어떻게 회원가입을 해야 하나요?	먼저, 카카오버스를 이용하기 위해서는 먼저 회원가입을 하셔야 합니다! 회원가입은 매우 간단하니 걱정하지 마세요 :)	카카오버스 앱을 처음 쓰려는데 단계별로 어떻게 회원가입을 해야 하나요?	먼저, 카카오버스를 이용하기 위해서는 먼저 회원가입이 필요합니다. 회원가입을 위해서는 몇 가지 단계를 거쳐야 하는데요. 첫 번째로, 앱 스토어나 구글 플레이에서 "카카오T"나 "카카오 맵"과 같은 어플리케이션을 다운로드하고 설치해주세요. 설치한 후에는 해당 프로그램의 실행화면에서 '계정 만들기' 또는 '로그인' 버튼을 찾아 클릭하시면 됩니다. 그럼 간단하게 이메일 주소만으로도 간편하게 계정을 만들 수 있습니다! 이렇게 만든 계정으로 로그인을 하면 카톡 아이디로도 인증할 수 있으니 편리한 방법으로 진행해보세요.(구체적이고 세부적인 방법 명시)
내가 갤러리에서 사진을 가져와서 편집하려고 하는데 스타일을 선택할 수 있는 기능을 모르겠어. 어떻게 하면 되지?	갤러리에 들어가서 사진 편집하기를 누르시면, 아래쪽에 다양한 스타일들이 나열되어 있습니다. 원하시는 스타일로 변경하시면 됩니다!	내가 갤러리에서 사진을 가져와서 편집하려고 하는데 스타일을 선택할 수 있는 기능을 모르겠어. 단계별로 어떻게 하면 되지?	갤러리에 들어가서 사진편집하기를 누르시면, 다양한 스타일들이 나열되어 있는 것을 보실 수 있습니다. 원하시는 스타일로 변경하고 싶으시다면, 아래에 "스타일"이라는 메뉴가 있으니 그곳을 클릭하시면 됩니다! 이렇게 하면 원하는 느낌으로 사진을 꾸밀 수 있어요 :)(구체적 방법 명시)
네이버 앱에서 글자를 크게 보는 방법은 어떻게 되나요?	글자가 작아서 불편하신가요? 그렇다면, 네이버 앱에서는 '돋보기'기능으로 큰 글자로 볼 수 있습니다! 이 기능은 네이버 앱의 왼쪽상단에 있는 세 줄 메뉴에 포함되어있어요.	네이버 앱에서 글자를 크게 보는 방법은 단계별로 어떻게 되나요?	글자가 작아서 불편하신가요? 그렇다면 네이버 앱에서는 "돋보기"라고 적힌 부분을 누르시면, 화면이 전환되어 글씨를 확대해서 보실 수 있습니다!이렇게 하면 편리한 방법으로 글을 읽으실 수 있어요.(구체적 방법 명시)
유튜브에 비디오 올리려면 어떻게 해야 해?	유튜브에서 동영상을 올리고 싶으시다면, 먼저 유튜브 계정을 만들어야 합니다! 계정 만들기부터 시작해서 다양한 기능들을 배워보세요.	유튜브에 비디오 올리려면 단계별로 어떻게 해야 해?	먼저, 유튜브 계정을 만드신 후, '내 프로필' 페이지로 들어가세요. 거기서 '업로드' 버튼을 누르시면 됩니다. 그리고 나서 원하는 동영상파일을 선택하고, 제목과 태그(추가정보)를 작성해 주세요. 마지막으로 공개설정에서 전체공개나 비공개 등의 옵션을 결정하시면 됩니다. 이렇게 하면 여러분의 멋진 동영상을 많은 사람들에게 공유할 수 있습니다!(구체적 방법 명시)
마이크로 SD 카드를 스마트폰에 넣는 방법은 어떻게 되나요?	스마트폰에서 마이크로 SD카드는 보통 옆면에 위치하고 있습니다. 마이크로 SD카드가 잘 있는지 확인해 보시고, 만약 없다면 근처의 대형마트나 전자제품매장에서 구매하실 수 있습니다!	마이크로 SD 카드를 스마트폰에 넣는 방법은 단계별로 어떻게 되나요?	스마트폰에서 마이크로 SD카드를 삽입하려면, 먼저 전원버튼과 볼륨키 사이에 있는 작은 구멍이 있습니다. 그곳을 통해 카드의 핀을 밀어 넣으면 됩니다. 이렇게 하면 쉽게 마이크로 SD카드가 장착됩니다!(구체적 방법 명시)

4) 고도화 방안 3 - LoRA(Low-Rank Adaptation)

■ 적은 자원으로도 모델의 성능을 높게 유지하는 튜닝 방법인 PEFT 기법 적용

- PEFT(Parameter Efficient Fine-Tuning)는 모델의 일부 파라미터를 튜닝함으로써 모델의 성능을 적은 자원으로도 높게 유지하게 하는 방법임
- 초기에는 사전학습 된 모델의 사이에 학습 가능한 작은 feed-forward networks를 삽입하는 구조인 어댑터(adapter) 방식을 많이 사용하였음
- 그러나 최근에는 사전학습 된 모델에 고정된 가중치(weight)를 갖는 학습 가능한 랭크 분해 행렬(rank decomposition matrix) 삽입하는 방식인 LoRA(Low-Rank Adaptation) 기법이 주로 사용되며, LoRA는 중간에 학습 가능한 파라미터를 삽입했다는 점에서 어댑터와 다른 구조라 할 수 있음


[그림 2-16] LoRA 가중치 고정 방식[23]



- II-2-3)에서 기술한 바와 같이, LLM의 fine-tuning 시 학습 가능한 파라미터 수를 줄여 GPU 사용을 효율적으로 사용함에도 불구하고, 적은 파라미터 수로도 기존 모델만큼이나 높은 정확도를 보임
- Llama2-7B 모델의 fine-tuning 시 사용되는 GPU 메모리 할당량을 비교해본 결과 다음과 같음

- ① LoRA 적용 전 fp16(매개변수 당 2바이트)에서 모델을 로드하는 것을 고려한다면 약 84GB의 GPU 메모리가 필요[24]
- ② LoRA를 적용 후, 모델 매개변수는 int8(1바이트)에 로드될 수 있으며, 훈련 가능한 1GB 매개변수는 fp16(2바이트)에 로드됨. 그라데이션(fp16), 최적화 상태(fp32) 및 활성화(fp32)의 크기는 약 7~9GB로 집계됩니다. 그러면 [그림 2-17]에 표시된 것처럼 로드된 모델의 전체 크기가 15~17GB로 fine-tuning 됨[24]

[그림 2-17] LoRA 적용 전/후 GPU 메모리 할당량[24]




- 선행 연구 결과를 요약하자면, Llama2-7B의 fine-tuning 수행 시 LoRA 적용 전의 경우 GPU 메모리 할당량은 84GB이나, 적용 후 약 15~17GB의 메모리만 할당하는 것을 확인함
- 따라서 선행연구 결과를 토대로 본 연구에서는 한정된 자원 안에서 신속하고 고효율의 성능을 나타내기 위하여 LoRA를 적용한 fine-tuning을 실시하였음

5) 고도화 방안 4 – RLHF(Reinforcement Learning with Human Feedback)

■ Llama 2-chat의 RLHF(인간피드백형 강화학습) 방안

- Llama-2-chat은 SFT와 RLHF를 모두 사용하여 fine-tuning을 수행하였음
- 이 과정에서 SFT는 RLHF 프레임워크의 필수 구성 요소 역할을 하며 모델의 응답을 인간의 선호도 및 기대치에 가깝게 조정하는 역할을 함
- 본 연구에서는 Llama 2-chat 강화학습 방법을 활용하여 SFT와 RLHF fine-tuning 방법을 진행하였으며, [그림 2-18]의 Stage 2와 3의 방법론을 활용하였음
- SFT와 RLHF은 LLM을 작업(Task)에 맞추어 동작하도록 하는 fine-tuning 방안으로 prompt와 response로 구성된 label을 포함한 SFT 데이터셋을 사용함

[그림 2-18] Llama 2-chat SFT와 RLHF Fine-tuning 방법[12, 재가공]



■ SFT와 RLHF를 활용한 강화학습 진행 방안

- ① SFT 수행 후 사용자가 입력한 prompt에 대해 답변을 인간의 선호 내용에 맞춰 조정된 response 생성
- ② 생성된 response에 대해 reward model이 적합한지 평가
- ③ Reward model에서 높은 score를 받은 prompt와 response만을 sampling 해서 SFT 데이터셋을 구축


④ 구축된 SFT 데이터셋에 대한 Aligned 모델에 대한 fine-tuning 작업 진행

- ▶ Reward model이 가장 적합하다고 한 response를 추출한 것을 SFT에 적용할 데이터셋으로 만들어 다시 fine-tuning을 하는 과정

⑤ 위의 1번과 4번의 과정을 4~5회 반복하여 최적의 aligned model 선택

- ▶ SFT 모델 훈련 → Reward model 훈련 → SFT 데이터구축 → SFT 모델 훈련의 과정을 반복

[그림 2-19] SFT와 RLHF 기반 답변 생성 프로세스[25]



■ Reward Model 입력데이터 구축 및 SFT 모델의 성능 평가 수행

① Reward model을 통한 강화학습

- 인간 Labeler(or trainer)가 선별한 샘플 데이터셋(QA, history)으로 llama2-ko-chat 모델에 fine-tuning을 실시
- Fine-tuning된 SFT 모델에서 생성된 여러 답변 후보 중, reward model을 통해 무엇이 더 좋은 답변인지 순위를 매겨 점수화한 데이터셋 수집
- 수집된 데이터셋을 이용하여 기존 llama2-ko-chat 모델에 학습을 진행

② Reward model 아키텍처 구성

- 본 연구에서는 transformers 라이브러리를 사용한 BERT 기반의 시퀀스 분류 모델을 Reward model로 사용(bert-base-multilingual-cased-nsme)
- Reward 방식은 각 state마다 좋고(positive) 나쁨(negative)을 알 수 있도록 classification 방식을 적용

[그림 2-20] BERT 기반의 reward model

```
def preprocess(text):
    new_text = []
    for t in text.split(" "):
        # = '@user' if t.startswith('@') and len(t) > 1
        #t = 'http' if t.startswith('http') else t
        new_text.append(t)
    return " ".join(new_text)

LOCAL_MODEL_PATH = "bert-base-multilingual-cased-nsmc"
```

- LLM(llama2-ko-chat)이 생성한 결과에 대한 Reward model 평가를 기반으로 모델을 조정하고 개선
- LLM(llama2-ko-chat)이 생성한 텍스트 데이터를 입력으로 받아, 텍스트 분류를 통해 올바른 문장이면 1에 가깝고 올바르지 않으면 0에 가깝도록 scoring

[그림 2-21] Reward model scoring 예시

```
text = "택시업을 이용하실 때 자동 결제 수단이라는 것은 본인의 결제 방법을 미리 등록해두는 것을 말해요. 예를 들어, 신용카드나 페이앱 등을 등록해두면 이용할 때마다 별도의 결제 과정을 거치지 않아도 자동으로 결제가 이루어져요. 이렇게 등록해두시면 보다 편리하게 택시를 이용하실 수 있습니다. 등록 방법은 앱 내 설정 메뉴에서 진행하실 수 있어요."
text = preprocess(text)
encoded_input = tokenizer(text, return_tensors='pt')
output = model(**encoded_input)
scores = output[0][0].detach().numpy()
scores = softmax(scores)
ranking = np.argsort(scores)
ranking = ranking[::-1]
for i in range(scores.shape[0]):
    l = config.id2label[ranking[i]]
    s = scores[ranking[i]]
    print(f"{i+1}) {l} {np.round(float(s), 4)}")
```

✓ 0.1s

Python

1) negative 0.5858
2) positive 0.4142

③ Reward model 아키텍처 구성


- 모델이 생성한 답변 문장에 대해 시퀀스 분류 모델을 사용하여 score(positive to negative) 평가를 진행

[그림 2-22] Reward model을 통한 scoring 예시(history 기반 dataset)

instruction	input	output	rewardmodel score	Label_1	Score_1	Label_2	Score_2
질문에 맞	카카오톡 프로필을 꾸밀 때	프로필에 다양한 장식도구를 사용해서 나만의 개성을 표	0.9954	positive	0.9977	negative	0.0023
질문에 맞	블로그에 글을 쓸 때 어떤	주글쓰기라는 것은 다양한 주제가 가능합니다.일상적인	0.995	positive	0.9975	negative	0.0025
질문에 맞	월드 시민랜드에서는 어떤	네, 월드시민랜드에는 다양한 종류의 재미있는 게임이	0.9948	positive	0.9974	negative	0.0026
질문에 맞	제페토에서 나를 닮은 아바타	먼저, 제페토에 접속하신 후 "마이룸"으로 들어가주세요	0.9946	positive	0.9973	negative	0.0027
질문에 맞	메타버스에서 실제 공간을	메타버스는 현실 세계의 다양한 공간과 시설들을 그대로	0.9944	positive	0.9972	negative	0.0028
질문에 맞	카카오 뷰에서 내가 관심 있	카카오뷰에서는 다양한 분야의 소식들을 한눈에 볼수있	0.9934	positive	0.9967	negative	0.0033
질문에 맞	내일 친구들과 서울에 놀러	서울시에는 정말 많은 관광명소가 있습니다! 내일 방문	0.9934	positive	0.9967	negative	0.0033
질문에 맞	사진을 꾸미려고 하는데 어	원하시는 사진에 어울리는 색상과 스타일을 찾아보세	0.9922	positive	0.9961	negative	0.0039
질문에 맞	서울시 명소 10곳에서 어떤	서울시의 다양한 명소에서 360도 뷰가 제공됩니다! 24	0.992	positive	0.996	negative	0.004
질문에 맞	메타버스에서는 어떤 활동	메타버스는 다양한 활동을 즐길수 있는 공간이에요!예	0.9918	positive	0.9959	negative	0.0041
질문에 맞	메타버스에 대해서 더 자세	메타버스는 우리가 일상적으로 경험할 수 없는 것들을	0.9918	positive	0.9959	negative	0.0041
질문에 맞	각 시즌별 체험 미니게임이	봄시즌에는 꽃과 관련된 다양한 게임들이 준비돼있습	0.9916	positive	0.9958	negative	0.0042
질문에 맞	내 전화벨 소리는 너무 지루	전화벨이 울릴때, 특별하고 기억에 남는 소리를 만들어	0.9912	positive	0.9956	negative	0.0044
질문에 맞	메타버스는 무엇이고 어떻	거최근에 많은 사람들이 메타버스라는 용어를 사용하고	0.991	positive	0.9955	negative	0.0045
질문에 맞	사진을 꾸미는 기능 외에도	이외에도 다양한 효과들을 추가하실수있습니다!예쁜	0.991	positive	0.9955	negative	0.0045
질문에 맞	시장실의 시민의 의견	함을 시장의 발전을 위해 시장실실을 방문하시면, 시장과 직	0.991	positive	0.9955	negative	0.0045
질문에 맞	메타버스에서는 어떤 식으로	메타버스는 디지털 세상에 기반한 새로운 유형의 사회	0.9908	positive	0.9954	negative	0.0046
질문에 맞	광장에 있는 시즌별 체험	미 봄, 여름, 가을, 겨울마다 다양한 계절에 어울리는 체험	0.99	positive	0.995	negative	0.005
질문에 맞	디지털 시대에 맞춰 사진	꾸요즘은 디지털 시대만큼, 사진을 꾸며서 모바일로 업	0.9892	positive	0.9946	negative	0.0054

- 프롬프트 결과로 나온 base, QA, history 데이터셋을 학습한 LLM 응답결과에 대한 score 결과 분석을 통해 선호도 score를 구하고 선호도가 적용된 데이터셋을 활용하여 LLM에 fine-tuning 실시
- score가 높게 나온 응답문 top-1000을 추출하여 모델에 미세조정하는 작업을 실시하였음

[그림 2-23] Reward model 학습 과정



■ Reward model을 통한 SFT fine-tuning을 통한 강화학습 결과 평가

- 기존의 강화학습 방식을 일부 변형하여 Language Model(BERT)이 주는 reward를 활용하여 강화학습을 진행하였음
- SFT모델에서 생성한 데이터셋을 대상으로 하여 reward model에서 average score가 높은 데이터셋을 추출한 후 다시 SFT 모델에 튜닝을 하여 파라미터를 보정하는 작업을 실시함
- base, QA, history 데이터셋을 학습한 LLM의 응답에 대한 scoring 결과, QA 데이터셋을 학습하였을 때 가장 높은 positive score를 가졌고, 총 평균 결과 기존 모델 대비 20% 향상된 결과를 보였음

[표 2-16] Reward model scoring 결과

학습모델	negative score	positive score	total average score
Llama2-base	-0.4719	0.4938	0.0227
QA_fine-tuning	-0.3530	0.6470	0.2940
history	-0.4193	0.5807	0.1614

SEOUL

DIGITAL

FOUNDATION

AI 서비스 연구개발

생성형 AI 대규모 언어모델을 활용한 LLAMA-SDF 개발

제3장

결론

제3장 | 결론

- 본 연구에서는 오픈소스 기반 언어모델을 활용하여, 어르신 디지털 상담을 위한 고도화된 LLM 기반 챗봇 모델 개발을 연구 목표로 하였으며 목표를 달성하기 위해 모델 선정 및 성능 고도화 작업 수행하였음
- 오픈소스 여부, 서빙 비용, 한국어 답변 성능을 기준으로 오픈소스 기반 대규모 언어모델 후보군 중 Llama2, Polyglot-ko 모델을 최종 모델 후보군으로 선정하고, 두 모델에 대한 파라미터별 GPU 할당량을 측정하였음. 그 결과 로컬 모델 사용 시 7B의 경우 24GB, 13B의 경우 40GB 수준, 70B도 50GB 이상의 서버 자원을 보유 시 모델 구동이 가능한 것을 확인함
- 한국어 사전 학습 비율의 문제로 Llama2와 Polyglot-ko의 파생모델인 Llama2-ko-chat과 KULLM에 대해 조사하고 평가를 수행하였음. 최종모델 선정을 위한 답변 성능 비교 결과, 'Llama2-ko-chat' 모델이 더 세부적이고 절차적인 답변을 제공하는 경향이 있다고 판단하여 최종모델로 선정함
- 모델의 고도화 방안으로 Instruction tuning, Prompt learning, LoRA, RLHF를 수행하였음. 고도화 방안 수행 시 응답 길이와 끝맺음 문제의 경우 파라미터 수정을 통하여 문제를 해결하였고, 답변의 성능 향상을 위해 다회턴(history) 기반 데이터셋을 활용하여 fine-tuning을 수행하였음
- Instuction tuning 결과, 기존 모델(base)에 비해 질문에 대한 이해도와 복잡하거나 다양한 맥락을 포함한 질문에 대한 응답 능력이 개선된 것을 확인하였음. Prompt learning의 경우 CoT 방안을 추가 적용함으로써 방법이나 기능을 요하는 답변의 경우 구체적인 방법에 대한 답변을 제공하였음. Reward model 보상 모델을 이용한 RLHF 결과, 기존 모델 대비 답변 성능이 20% 향상된 결과를 보였음

- 향후 연구에서는 하이퍼 파라미터 최적화 작업을 통해 모델의 답변을 좀 더 풍부하고 완성도 높게 하고, 더 나아가 데이터 검색 및 텍스트 생성의 결합한 정보를 제공하는 RAG(Retrieval-Augmented Generation)을 적용하여 더 신뢰성 있고 풍부한 답변을 제공할 예정임
- 개발된 모델은 새로운 주제에 관한 모델 파이프라인 구축 및 서비스 개발을 통한 상용화 및 구체화 작업이 가능하며, 이는 개발 모델을 기반으로 한 새로운 영역으로의 확장이 가능할 것으로 기대됨

참고문헌

- [1] 국가정보원, 챗GPT 등 생성형 AI 활용 보안 가이드라인, 2023
- [2] <https://www.researchandmarkets.com/reports/5775046/generative-ai-market-offering-software>
- [3] <https://www.gttkorea.com/news/articleView.html?idxno=6480>
- [4] 이준범, 명령어를 이해하는 오픈소스 언어 모델 KoAlpaca 개발기, 2023
- [5] <https://velog.io/@dongyoungkim/GPT-fine-tuning-7.-Glossary>
- [6] 미래에셋증권, [생성 AI] 제2의 기계시대, 2023
- [7] <https://klu.ai/blog/open-source-llm-models-august-2023>
- [8] <https://medium.com/@sasika.roledene/unlocking-llm-running-llama-2-70b-on-a-gpu-with-langchain-561adc616b16>
- [9] <https://discuss.huggingface.co/t/Llama-7b-gpu-memory-requirement/34323>
- [10] <https://ai.meta.com/research/publications/Llama-2-open-foundation-and-fine-tuned-chat-models/>
- [11] A Technical Report for Polyglot-Ko: Open-Source Large-Scale Korean Language Models, 2023
- [12] Llama 2: Open Foundation and Fine-Tuned Chat Models, Hugo Touvron et al, July 18-2023
- [13] <https://huggingface.co/kfkas/Llama-2-ko-7b-Chat/blob/main/LICENSE>
- [14] <https://github.com/nlpai-lab/KULLM>
- [15] <https://github.com/nlpai-lab/KULLM/blob/master/LICENSE>
- [16] LoRA: Low-Rank Adaptation of Large Language Models, 2021
- [17] <https://velog.io/@soyoun9798/Pre-training-fine-tuning>
- [18] <https://velog.io/@dongyoungkim/GPT-fine-tuning-5.-in-context-learning>
- [19] <https://velog.io/@dongyoungkim/OpenAI-GPT-fine-tuning-3.-memory>
- [20] <https://www.upstage.ai/blog/tech/ai-modeling/how-to-test-data-set>
- [21] Takeshi Kojima, Shixiang Shane Gu, Machel Reid, Yutaka Matsuo, Yusuke Iwasawa. Large Language Models are Zero-Shot Reasoners. arXiv:2205.11916v4 [cs.CL]. 2023
- [22] <https://colab.research.google.com/drive/1jXfyvoS8KY1sa9lsJz8cAptKTe-RZLjv?usp=sharing#scrollTo=RliDK1u56dSR>

- [23] Edward J. Hu, Yelong Shen, Phillip Wallis, Zeyuan Allen-Zhu, Yanzhi Li, Shean Wang, Lu Wang, & Weizhu Chen. LoRA: Low-Rank Adaptation of Large Language Models. arXiv:2106.09685. 2021
- [24] <https://infohub.delltechnologies.com/p/llama-2-efficient-fine-tuning-using-low-rank-adaptation-lora-on-single-gpu/>
- [25] <https://m.mk.co.kr/luxmen/view.php?sc=&year=2023&no=270542>

생성형 AI 대규모 언어모델을 활용한 LLAMA-SDF 개발

발행일 2024년 4월 11일

발행처 서울디지털재단
서울시 마포구 매봉산로31 에스플렉스센터 스마티움 16층

ISBN 979-11-92319-63-6

* 서울디지털재단의 승인 없이 본 자료의 무단 전재나 복제를 금지하며,
인용 시에는 출처를 밝혀주시기 바랍니다.

AI 서비스 연구개발

생성형 AI 대규모 언어모델을 활용한 LLAMA-SDF 개발

MAKING THE NEXT DIGITAL LEADERS



서울디지털재단의 미션(Mission)은 디지털 대전환을 통한 스마트시티 서울의 글로벌 경쟁력을 강화하며, 비전(Vision)으로 넥스트 디지털 생태계를 리딩하는 스마트 서울의 컨트롤타워 역할을 수행하며, 핵심가치(Core Value)로 혁신과 융합, 연결과 미래, 공정과 소통, 책임과 청렴을 추구합니다.

